

KT Mi:dm 2.0 Base / Mini

Technical Report Survey

한국 중심(Korea-centric) Bilingual LLM 들여다보기

 *Mi:dm 2.0 Korea-centric Bilingual Language Models* (KT Tech. Innovation Group)

 github.com/K-intelligence-Midm/Midm-2.0

손지연 · 26/4/21 · 도전! 수퍼 K-모델: 허깅페이스와 함께 한국 오픈소스 모델 사용해보기

목차

1. **Mi:dm 2.0?** — 모델 라인업과 포지셔닝
2. **Data** — 분류 체계 / 필터링 / 합성 데이터
3. **Pre-training** — DuS, Pruning & Distillation, Long-context
4. **Post-training** — SFT / Merging / Preference Optimization
5. **Evaluation & 실사용기** — 벤치마크와 우리가 써본 인상

본 발표는 테크 리포트의 목차 흐름을 그대로 따라가며 ablation과 데이터 설계 의사결정에 집중

1. Mi:dm 2.0?

Korea-centric AI · Base & Mini 라인업

1.1 Korea-centric AI?

"단순히 한국어를 처리하는 모델이 아니라, 한국 사회의 가치·인지 프레임·상식을 내재화한 모델"

- 기존 한국어 LLM의 한계
 - insufficient / low-quality 한국어 데이터
 - cultural alignment 결여 → 부자연스럽거나 감정적으로 어긋난 응답
- 목표: 단순 linguistic proficiency를 넘어 cultural nuance까지
- KT 자체 기술로 from scratch 학습
 - 오픈소스 weight 미사용
 - 아키텍처 설계부터 in-house

1.2 라인업: Base & Mini

두 개의 상호보완적 dense 모델

- **Mi:dm 2.0 Base (11.5B)**
 - 범용 foundation, context 32K, MIT
 - 8B → DuS(Depth-up Scaling)로 11.5B 확장
- **Mi:dm 2.0 Mini (2.3B)**
 - on-device·저자원 환경, context 32K, MIT
 - Base에서 pruning + multi-stage distillation으로 추출
 - intent understanding과 machine translation 특화
- 두 모델 모두 MIT 라이선스 → 연구·상업 사용 자유

1.3 아키텍처 한눈에 보기

핵심 design choice는 Base / Mini 동일, hidden size·FFN dim만 차이

- 공통
 - layers 48
 - attention: GQA (32 heads, head dim 128)
 - activation: SiLU
 - RoPE $\theta = 8,000,000$
 - context length 32,768
- 차이
 - Base: hidden 4,096 / FFN 14,336 / vocab 131,384
 - Mini: hidden 1,792 / FFN 4,608 / vocab 131,392 (tied word embedding)
- Mini도 layer는 48 → width pruning 위주로 설계, depth 보존

2. Data

다축 분류 → 8단계 필터링 → 합성으로 도메인 균형 맞추기

2.1 다차원·계층적 데이터 분류 프레임워크

모든 학습 샘플에 최대 5개 차원의 메타데이터 태깅

- **Language:** Korean / English / Code / Math / Multi
- **Source:** Organic (Web / News / Book / Paper / Encyclopedia / Gov ...) / Synthetic
- **Domain**
 - 6 major: Humanity / STEM / Applied Science / Health & Food / Life & Culture / ETC
 - 20 mid-level subdomains
- **Style:** Written / Spoken
- **Tone:** Formal / Informal
- 데이터 수집부터 학습까지 분포를 지속 모니터링
- 부족 도메인은 synthetic generation으로 보강 (feedback loop)

2.2 데이터 소스 구성

전체 데이터의 약 86%가 organic, 14%가 synthetic

- **Organic ~85.7%:** web 문서가 주축
- **공공 데이터 ~10%:** AIHub, 국립국어원(NIKL)
 - 표준어·공공 벤치마크 호환성 강화
- **고밀도 자료 ~0.71%:** 논문·도서·정부 문서·사전
 - 비중은 작지만 informational text·formal language 성능에 기여
- **Synthetic ~14%**
 - 한국어 도메인 불균형 보강
 - 한국 관련 지식이 부족한 부분을 채움
- 뉴스·도서·사전은 정식 라이선스 계약 후 내부 품질 기준 통과
- PII와 KT 고객 데이터는 학습에서 명시적 제외

2.3 한국어 웹 데이터 8단계 필터링 파이프라인

원시 CC의 80%+가 이 파이프라인에서 탈락 — 양보다 질

1. Document De-duplication

- TF-IDF cosine similarity

2. Heuristic Filtering

- 해시태그·반복 문장부호 등 handcrafted rules

3. Perplexity Filtering

- 비정상 n-gram perplexity 제거

4. Broken Document Detection & Correction

- 유니코드 손상 복구

5. Model-Based Quality Filtering

- 일반 품질 / 교육 품질 binary classifier ensemble

6. Toxic Content Filtering

- KT 자체 한국어 toxicity·bias taxonomy

7. Line-Level De-duplication

2.4 합성 데이터 (1) — 한국어 도메인 균형

STEM·경제 등 reasoning이 필요한 도메인이 한국어 코퍼스에 절대 부족

- 분포 분석 결과
 - Applied Science: 전체 토큰의 0.1% 수준
 - 초기 벤치마크에서 물리·화학·수학·CS·경제 영역 성능이 낮게 나옴
- 보강 방식
 - 고신뢰 오픈소스 자료를 seed로 확보
 - 도메인별 prompt 설계 → textbook 스타일·시나리오 narrative로 합성
 - 다양한 난이도, 다양한 reader profile로 생성
- reference: Phi-4 technical report, On the diversity of synthetic data ...

2.4 합성 데이터 (2) — 비채택 한국어 웹 문서 재구성

버려진 CC 문서 중 일부를 LLM으로 rewrite하여 회수

- 배경
 - 초기 raw CC의 80%+가 필터에서 탈락 → 회수 인센티브 큼
 - 일부 문서는 형식·내용은 나쁘지만 핵심 주제는 살릴 만함
 - rule-based로는 복원 어려움 → generative rewriting pipeline
- 2-stage prompt
 - i. **topic 분석 모듈**: 핵심 topic·관련 단락 index 추출
 - 광고·저작권 문구 등 irrelevant fragment 제거
 - 한 문서 안에 여러 unrelated 글이 섞인 케이스 분리
 - ii. **rewriting 모듈**: topic-relevant 내용만 발췌·재작성
- 재합성 후 동일한 8단계 필터를 다시 통과한 문서만 채택

2.4 합성 데이터 (3) — English Web의 구조적 augmentation

영어 웹 문서를 한국어로 rewrite (직역이 아닌 content-preserving rewrite)

- 한국 CC의 한계
 - 형식적 다양성이 부족 (뉴스·블로그·커뮤니티 위주)
 - 긴 구조화 문서나 intent-driven 형식(요약·QA·번역)이 적음
- 접근
 - 사용되지 않은 영어 web sample을 한국어 텍스트로 재작성
 - 직역 시 발생하는 idiom 오역, 도메인 용어 misinterpretation 회피
 - 예: 영어 web 문서 → 한국 수능 비문학 형식의 지문 + 문항 + 정답
- 합성 QA 데이터는 CoT-based verification 후 정답 일치 샘플만 retain

2.4 합성 데이터 (4) — Math/Code의 Long CoT

복잡한 reasoning을 위한 명시적 multi-step 풀이 시퀀스

- 각 example에 logically structured solution path 포함
- 풀이·해설은 주로 한국어로 작성
 - 모델이 한국어로 사고하는 reasoning 능력 학습
- pre-training-ready text segment 형태로 학습 코퍼스에 직접 포함
- 효과: math · programming · structured QA에서 강한 baseline 형성
- LongCoT는 단순 데이터 증강이 아닌 **reasoning curriculum**의 사전 주입

3. Pre-training

3-stage 파이프라인 · DuS · Pruning-Distillation · Long-context

3.1 모델 라인업 확장 — 3-stage Pipeline

한 번 잘 학습한 8B를 두 방향(확장 / 압축)으로 활용

- **Stage 1**
 - 8B Mi:dm 2.0 Base를 from scratch 학습
 - 32 layers, 입력 길이 ~8,000 토큰
 - 광범위 topic·domain을 다루는 foundation 확보 목적
- **Stage 2**
 - Stage-1 checkpoint에서 출발
 - DuS로 32 → 48 layers 확장 → 11.5B
 - ultra-high-quality data로 continual pre-training
- **Final stage (long-context)**
 - RoPE base frequency 조정 → 8K → 32K context로 확장
 - Base와 Mini 둘 다 적용

3.1.1 Mi:dm 2.0 Base — Depth-up Scaling

strategically choosing layers

- with strong representational capacity

1. embedding representations의 changes 측정

- before and after each layer
- by cosine similarity

2. 높은 cosine similarity scores를 가진 레이어들 선택

- assumption: stably preserve the input information with minimal degradation
- 7th ~ 29th layers (close to 1.0)

confirm

- internal experiments: 비슷한 구조의 다른 language models을 대상
- 비슷한 패턴 reference: <https://arxiv.org/html/2309.00071v3> (YaRN)

3.1.1 DuS — verify & continual pre-training

verify

- evaluate the performance in its initial state
- 구조만 확장하고 추가 학습을 하지 않은 Base-init이 원본 8B와 비슷한 성능
 - layer 선정이 유효했다는 신호

continual pre-training (2 stage)

1. ensure stable convergence
 - 확장 직후 안정 수렴 보장
2. strength Korean / STEM domain
 - curated Korean data + custom-generated synthetic data 사용

phase: Warmup-Stable-Decay scheduler, peak learning rate $3e-4$

- decaying linearly to 0.0
- during the final 10% of training

3.1.2 Mi:dm 2.0 Mini — Pruning & Distillation

teacher → student 격차가 크면 distillation이 불안정 → 중간 단계(assistant teacher) 도입

- **Stage 1**

- Base(11.5B)에 width pruning → Base-half (~5B)
- Base를 teacher로 두고 distillation

- **Stage 2**

- Base-half에 추가 width pruning → Mini (2.3B)
- Base + Base-half 둘 다 teacher로 사용 (multi-teacher distillation)
- word embedding을 tied 구조로 마무리

- Width를 줄이고 depth(48)는 유지

- 같은 파라미터 budget이면 deeper > wider라는 prior에 근거
- reference: Minitron (LLM pruning and distillation in practice)

3.1.2 Pruning-Distillation — proxy 검증

1.8B-parameter proxy 실험으로 전략 유효성 검증

- 비교 대상
 - 1.8B-scratch: 처음부터 학습
 - 1.8B-distill: Base를 teacher로 pruning + distillation
- 결과 (요지)
 - 대부분 벤치마크에서 distill > scratch
 - 특히 한국어·reasoning 계열(HAERAE·GSM8K)에서 격차 큼
 - 학습 비용은 ~4.5× 절감
- 기타 셋업
 - width pruning 대상: hidden dimension·MLP dimension 위주
 - calibration: Stage-2 pre-training data에서 1,024 sample
 - distillation: peak lr 1e-4, warm-up + cosine decay

3.1.3 Long-context Extension — 8K → 32K

RoPE base frequency를 키우고, 학습 시퀀스는 더 길게

- RoPE θ : 10,000 → 8,000,000
 - reference: "Base of RoPE bounds context length"
- 학습 시퀀스
 - 최대 ~65,000 토큰 (target context보다 길게 학습)
 - 짧은 데이터를 packing하여 catastrophic forgetting 완화
- 학습 setting
 - 2,000 step
 - learning rate $1e-5$ 고정
 - warm-up 없음

3.2 학습 비용

Mini는 student-only 산정, Base는 본격 대규모 학습

- 인프라
 - NVIDIA H100 GPU cluster
 - Microsoft Azure CycleCloud 기반
- 총 FLOPs
 - Mi:dm 2.0 Mini (2.3B): 4.57×10^{21}
 - Mi:dm 2.0 Base (11.5B): 1.74×10^{23}
- 효율화 기법
 - data / tensor / pipeline parallelism
 - quantization
 - 자체 training framework 확장

4. Post-training

SFT → Weight Merging → Preference Optimization (RL)

4.1 Post-training의 6대 목표 능력

서비스 환경에 필요한 capability를 명시적으로 정의

1. **Instruction-Following (IF)** — 형식·길이·스타일 제약 준수
2. **Reasoning** — 다단계 수학·논리
3. **Retrieval-Augmented Generation (RAG)** — 외부 지식 활용
4. **Agent / Tool Use** — function calling, MCP 표준 기반
5. **Safety** — harmlessness · honesty · AI 역할 일관성
6. **Long Context Handling** — 긴 문서에서 정보 유지·참조
 - pre-training의 unstructured corpus와 달리 multi-turn / role 기반 구조 사용
 - chat template은 LLaMA 4 포맷 채택 (System / User / Assistant / Tool)

4.2.1 SFT 전략 — Mix → 다중 학습 → Merge

여러 SFT 모델을 만들고 weight merging으로 통합

- batch 구성
 - 여러 capability 데이터를 혼합해 균형 확보
 - 영어→한국어 cross-lingual transfer를 위해 번역 데이터 일부 포함
 - 고품질 영어 데이터로 한국어 성능을 같이 끌어올리는 전략
- 학습 후
 - capability별 SFT 모델 여러 개 학습
 - mergekit 계열로 weight merging
 - merge ratio도 실험적으로 비교 후 선정
- 구조 측면
 - data / tensor / pipeline parallelism 그대로 활용
 - 멀티턴 구조로 데이터 저장 → 학습·추론 일관성 유지

4.2.2 Preference Optimization

SFT는 "정답"을, Preference는 "사용자 기대에 부합하는 응답"을 학습

- 사람·AI preference 라벨 데이터 사용
- 우선순위 속성
 - safety
 - 신뢰성 (reliability)
 - 유용성 (usefulness)
- baseline SFT 대비
 - 더 정제된 응답 생성
 - usability·trustworthiness·user satisfaction 향상
- General Chat의 Core Set Construction Pipeline
 - 9 major + 26 sub-categories × 6 domain × 20 mid-domain
 - 도메인-기능 매트릭스로 cell-level coverage 관리

4.3 Capability 데이터 (1) — IF & Reasoning

IFEval 기반 instruction taxonomy + LongCoT 기반 reasoning

- Instruction-Following
 - 47개 제약 조합 → 37개 instruction type으로 체계화
 - style / tone / target / format / length / language / examples / constraints
 - LLM 또는 crowdworker가 user request 생성 → 응답 후 constraint 만족 여부 / 정확도 평가
 - 자체 KoIFEval에서 baseline 대비 **+12%p** 개선
- Reasoning
 - target: 고등 수준 MWP, MathCoder 스타일 코드 reasoning
 - OpenThoughts 방식: reasoning-specialized 모델로 풀이 생성 → LLM-as-Judge로 검증
 - 검증 후 최종 답만 추출하여 SFT
 - HRM8K **+7%p**, MATH **+13%p**, MMMLU **+19%p**

4.3 Capability 데이터 (2) — RAG & Tool Use

General RAG, Math RAG 별도 파이프라인 / MCP 표준 기반 Tool Use

- RAG
 - 질문을 **factual / reasoning** 두 종류로 명시 분류 (prompt에 반영)
 - PDF → HTML → Markdown 변환 후 키워드 약 10개 추출
 - 난이도(easy / medium / hard)와 question type 다양화
 - "오류" "재계산" 키워드 포함 데이터는 자동 제거
- Tool Use
 - **40개 실생활 토픽 / 249개 함수**, JSON schema로 정의
 - persona × scenario × 1~3 tool 조합으로 multi-turn 대화 합성
 - 응답 6 카테고리: 추가 정보 요청 / tool 호출 / 호출 결과 / 결과 기반 응답 / chit-chat / 미지원 안내
 - tool 미지원·인자 오류 등 exception handling 시나리오 포함

4.3 Capability 데이터 (3) — Safety & Long Context

Safety는 RL 단계에서 +24%p의 큰 효과

- Safety
 - 7대 카테고리 (성·위반·폭력·차별·정치·재난·욕설), **56개 subcategory**
 - 평가 기준 3축: harmlessness / honesty / AI 역할 일관성
 - 거부, 거부 사유, 전문가 안내, AI 역할 선언 등 템플릿 표준화
 - RL 기반 safety 데이터: **+24%p 향상**, over-rejection도 함께 감소
- Long Context
 - 4K ~ 32K 문서를 1K 간격으로 chunking, 각 토큰 범위당 2.2K 문서/언어
 - mini-context를 0%, 10%, ..., 100% 위치에서 추출 → positional bias 완화
 - QA를 LLM으로 생성 후 Judge 점수 **9/10 이상만 채택**
 - Needle-in-Haystack / RULER에서 강한 결과

5. Evaluation & 실사용기

벤치마크 · Human Eval · Responsible AI · 우리 프로젝트 관점

5.1 Quantitative — 영어 / 한국어 벤치마크

Korea-centric 벤치마크에서 KMMLU SOTA, HAERAE 강세

- General English
 - MMLU, HellaSwag, GSM8K 등 표준 셋
- Korean Specific
 - **KMMLU**: 한국 시험 기반 35,030 문항, 45 과목
 - 동급/상위 모델 대비 top-tier zero-shot 결과
 - 참고: KMMLU 평균 인간 성능 62.6%
 - **HAE-RAE Bench**: 한국어·문화 지식 평가
 - 11.5B 급에서 글로벌·국내 동급 오픈소스 대비 우위라고 주장 (자세한 표는 PDF 참조)
- 한국어 reasoning을 같이 보려면 HRM8K도 후보

5.2 Human Evaluation & RAI

자체 시나리오 기반 평가 + 책임감 있는 AI 검증을 별도 트랙으로

- Human Evaluation
 - 실제 사용 시나리오 prompt 기반 평가
 - 언어·인문학·사회과학 task에서 강한 결과
- RAI Evaluation 3축
 - i. **Scenario-based**: 한국 사회 맥락의 borderline 쿼리
 - ii. **Benchmark**: 공개 safety / bias 벤치마크
 - iii. **Red Teaming**: 의도적 공격 시도에 대한 견고성
- 단순 정확도가 아닌 문화적·윤리적 적정성까지 평가에 포함

5.3 한계 (리포트 자체 명시)

bilingual 모델로서의 명확한 스코프와 위험 영역 공개

- 학습 데이터는 주로 한국어/영어
 - 그 외 언어는 보장 안 됨
- 전문 분야의 신뢰성 보장 안 됨
 - 법률 / 의료 / 금융 등
- 비윤리적 표현, 사실 오류 가능성 잔존
 - 필터링했으나 완벽하지 않음
- 사용자 데이터·KT 고객 데이터는 학습에 미사용으로 명시
 - PII 제외, 라이선스·provenance 엄격 관리

5.4 우리 프로젝트 관점 — 실사용기 & 실험 후보

MIT + 한국어 강점 + 적당한 사이즈 = 6명 규모 프로젝트에 잘 맞는 모델

- 환경 친화성
 - MIT 라이선스
 - GGUF / vLLM / LM Studio 공식 지원 → 회의 시연 부담 낮음
- 하드웨어
 - Mini: 노트북 GPU·단일 GPU OK
 - Base 11.5B: A100 1장 또는 RTX 4090 BF16 가능
- 시도해볼 만한 작업
 - Mini 2.3B로 의도 분류·번역 LoRA 파인튜닝 (리포트가 강조한 특화 영역)
 - Base에서 LongCoT 데이터 reasoning SFT 재현 → HRM8K / MATH 추적
 - DuS layer 선택 ablation — 다른 한국어 base에 cosine 분석 적용
 - KMMLU / HAE-RAE 채점 파이프라인 구축 (HRET 활용)

5.5 정리 & 토론 거리

리포트의 강점과, 같이 이야기해 보고 싶은 빈칸들

- 강점
 - 데이터 품질 우선 + 정량 ablation 풍부
 - 한국어 합성 파이프라인의 디테일 공개
 - DuS layer 선정 근거를 cosine similarity로 정량화
- 빈칸 / 토론
 - SFT / Preference 데이터의 정확한 양·출처는 비공개 부분 다수
 - 비교 모델군의 세팅 일관성 (HRET 같은 표준화 툴이 좋음)
 - Mini를 진짜 on-device(예: 폰)에서 어디까지 돌릴 수 있는가
 - 한국어 RAG에서 공공 문서의 PDF→Markdown 변환 품질이 실서비스 병목일 듯

Q & A

Discord에서 이어서 이야기해요

 github.com/K-intelligence-Midm/Midm-2.0

 huggingface.co/K-intelligence

 *Mi:dm 2.0: Korea-centric Bilingual Language Models*, KT Tech. Innovation Group